

Investigação Experimental de Resoluções de Entrada na Segmentação Semântica de Cenas Urbanas com DeepLabV3

Izabela da Silva Lisboa¹

¹Curso de Tecnologia em Análise e Desenvolvimento de Sistemas – Instituto Federal do Piauí (IFPI)

Campus Corrente, Corrente – PI – Brasil

cacor.202512tads0005@aluno.if-pi.edu.br

Abstract. *Semantic image segmentation plays a fundamental role in the development of autonomous driving systems and mobile robotics. This paper presents the results of an experimental investigation evaluating the impact of input resolution on the performance of the DeepLabV3 architecture equipped with a ResNet-50 backbone, using the CamVid urban driving-scene dataset as a publicly accessible substitute for Cityscapes. Two experimental setups were trained end-to-end for 5 epochs each: Experiment 1, with a reduced resolution of 128x256 pixels, and Experiment 2, with a higher resolution of 256x512 pixels. Results, obtained from real GPU training on Google Colab, show that Experiment 2 achieved a lower final validation loss (0.5448 against 0.7071) and a higher validation mIoU (36.43% against 31.28%), supporting the hypothesis that higher spatial resolution improves boundary delineation, although both experiments exhibited non-monotonic validation curves consistent with the limited size of the training set.*

Resumo. *A segmentação semântica de imagens desempenha papel fundamental no desenvolvimento de sistemas de direção autônoma e robótica móvel. Este trabalho apresenta os resultados de uma investigação experimental que avalia o impacto da resolução de entrada no desempenho da arquitetura DeepLabV3 com backbone ResNet-50, utilizando o CamVid, um dataset de cenas urbanas de trânsito publicamente acessível, adotado como alternativa ao Cityscapes. Foram treinados dois experimentos, de ponta a ponta, por 5 épocas cada: o Experimento 1, com resolução reduzida de 128x256 pixels, e o Experimento 2, com resolução superior de 256x512 pixels. Os resultados, obtidos de treinamento real em GPU no Google Colab, mostram que o Experimento 2 alcançou menor perda de validação final (0,5448 contra 0,7071) e maior mIoU de validação (36,43% contra 31,28%), corroborando a hipótese de que maior resolução espacial melhora a delimitação de bordas, embora ambos os experimentos tenham apresentado curvas de validação não monotônicas, condizentes com o tamanho reduzido do conjunto de treinamento.*

1. Introdução

Nos últimos anos, a Inteligência Artificial (IA) aplicada à Visão Computacional tem experimentado um crescimento vertiginoso, impulsionado por algoritmos de Deep Learning capazes de extrair e decodificar padrões visuais complexos sob variadas condições de perspectiva. Dentre as tarefas fundamentais nesta área, a segmentação semântica se destaca por atribuir uma classe de forma densa — isto é, pixel a pixel — a elementos contidos em uma cena urbana, permitindo a correta interpretação do ambiente ao redor por sistemas automatizados.

A escolha de hiperparâmetros arquiteturais e das características dimensionais do dado de entrada constitui um desafio central na engenharia desses modelos. Mudanças na resolução das imagens injetadas na rede podem mitigar ou amplificar a perda de informação espacial. Em cenários reais como a direção autônoma, mapear com precisão objetos pequenos e bordas de vias, calçadas e pedestres distantes é um requisito crítico de segurança operacional.

Para investigar essa relação, este trabalho realiza uma investigação experimental focada no impacto de duas resoluções de entrada distintas utilizando a arquitetura DeepLabV3 acoplada a um extrator de características ResNet-50, treinada de ponta a ponta e comparando o comportamento das curvas de aprendizado e das métricas finais obtidas em cada configuração.

O restante deste artigo está organizado da seguinte forma: a Seção 2 apresenta a fundamentação teórica sobre segmentação semântica de cenas urbanas e as arquiteturas DeepLabV3 e ResNet-50; a Seção 3 descreve a metodologia experimental, incluindo o conjunto de dados, o pré-processamento, a configuração dos experimentos e as métricas de avaliação; a Seção 4 apresenta e discute os resultados quantitativos e qualitativos obtidos, incluindo as limitações do estudo; e a Seção 5 traz as conclusões e sugestões de trabalhos futuros.

2. Fundamentação Teórica

2.1. Segmentação Semântica em Cenas Urbanas

A segmentação semântica de cenas urbanas consiste em classificar cada pixel de uma imagem capturada por câmeras embarcadas em veículos em categorias como via, calçada, edificação, vegetação, céu, veículo e pedestre. Diferentemente da classificação de imagens, que rotula a cena como um todo, essa tarefa exige a preservação de detalhes espaciais finos, especialmente nas transições entre classes adjacentes, como a fronteira entre a via e a calçada.

Historicamente, as primeiras redes totalmente convolucionais para essa tarefa, como a FCN de Long et al. (2015), substituíram as camadas densas

de classificadores por convoluções e camadas de upsampling, permitindo saídas de resolução completa a partir de um backbone de classificação. Arquiteturas com conexões de salto simétricas, como a U-Net (Ronneberger et al., 2015), popularizaram-se em cenários com poucos dados, enquanto a família DeepLab evoluiu especificamente para cenas complexas e multiescala, como as encontradas em ambientes de trânsito urbano — o principal alvo de aplicação deste trabalho.

Um desafio particular da segmentação de cenas de trânsito é o desbalanceamento natural entre classes: pixels de via e céu costumam dominar a imagem, enquanto classes críticas para a segurança, como pedestres, ciclistas e sinalização, ocupam uma fração muito pequena da área total. Esse desbalanceamento torna a escolha da resolução de entrada especialmente relevante, pois resoluções muito baixas tendem a fazer com que objetos pequenos e distantes sejam completamente perdidos durante o processo de downsampling interno da rede, mesmo antes de chegar às camadas de classificação final.

2.2. Arquitetura DeepLabV3

O DeepLabV3 (Chen et al., 2017) incorpora a técnica de Agrupamento de Pirâmide Espacial Atrosa (Atrous Spatial Pyramid Pooling — ASPP). O ASPP emprega convoluções dilatadas (atrous), operando com diferentes taxas de amostragem, o que permite capturar o contexto multiescala dos objetos na cena de forma eficaz sem inflar excessivamente o número de parâmetros treináveis da rede — um ponto especialmente relevante para cenas urbanas, que contêm objetos de tamanhos muito variados, de veículos a placas de sinalização.

2.3. Backbone ResNet-50

Como extrator base (backbone) de mapas de características profundas, utilizou-se a rede residual ResNet-50 (He et al., 2016), pré-treinada no ImageNet. O mecanismo de conexões de atalho (skip connections) nativo da ResNet resolve satisfatoriamente o problema da degradação e do desvanecimento do gradiente em arquiteturas de muitas camadas, garantindo fluxos estáveis de retropropagação mesmo em redes profundas.

No contexto do DeepLabV3, a ResNet-50 é adaptada por meio de convoluções com passo modificado (dilated/atrous convolutions) nos últimos blocos residuais, de modo a manter um mapa de características com resolução espacial maior do que a obtida em uma ResNet-50 convencional de classificação, na qual a resolução é reduzida em fator 32. Essa adaptação, combinada ao módulo ASPP, é o que permite ao DeepLabV3 produzir máscaras de segmentação com maior riqueza de detalhes espaciais mesmo mantendo um backbone

relativamente compacto e amplamente disponível pré-treinado em bibliotecas como o TorchVision.

3. Metodologia Experimental

3.1. Base de Dados

O conjunto de dados originalmente planejado para este estudo era o Cityscapes Dataset, referência consolidada na literatura para percepção urbana. Entretanto, o acesso ao Cityscapes requer cadastro e autenticação em seu portal oficial, o que inviabiliza o download automatizado dentro do fluxo de um notebook. Para viabilizar um treinamento real e reproduzível dentro do prazo do projeto, adotou-se o CamVid Dataset (Cambridge-driving Labeled Video Database), um conjunto de dados também composto por cenas urbanas de trânsito, hospedado publicamente sem necessidade de autenticação, e amplamente utilizado na literatura como alternativa ao Cityscapes em tarefas de segmentação viária.

O CamVid utilizado está organizado em 12 classes (11 classes semânticas — via, calçada, edificação, poste, sinalização, vegetação, céu, pedestre, ciclista, veículo e cerca/mobiliário urbano — mais uma classe void/não rotulada). Os dados já estão previamente divididos em 367 imagens de treino, 101 imagens de validação e 233 imagens de teste.

Apesar de possuir um número de classes e um volume de imagens menores do que o Cityscapes original, o CamVid preserva as características fundamentais do problema investigado neste artigo: cenas capturadas a partir de um veículo em movimento, contendo vias, calçadas e obstáculos urbanos, com anotações densas pixel a pixel. Isso torna o dataset adequado para o objetivo específico deste estudo, que é comparar o efeito da resolução de entrada — e não estabelecer um novo estado da arte absoluto em segmentação de cenas urbanas.

3.2. Pré-Processamento

Para cada um dos dois experimentos, as imagens e suas respectivas máscaras foram redimensionadas para a resolução-alvo correspondente, com interpolação bilinear para as imagens RGB e interpolação do tipo vizinho mais próximo para as máscaras, de modo a preservar os rótulos discretos das classes. Aplicou-se aumento de dados (Data Augmentation) no conjunto de treinamento por meio de espelhamento horizontal aleatório (Horizontal Flip) com probabilidade de 50%. As imagens foram normalizadas utilizando as médias e desvios padrão do ImageNet, condizentes com o pré-treinamento do backbone ResNet-50.

3.3. Configuração dos Experimentos

A fim de estabelecer o impacto da escala espacial das imagens, delineou-se o teste sob dois cenários compartilhando os mesmos hiperparâmetros de base:

Experimento 1: rede processando imagens em baixa resolução espacial, fixada em 128×256 pixels.

Experimento 2: rede processando imagens em resolução média-alta, fixada em 256×512 pixels.

Ambos os modelos foram treinados por 5 épocas, com semente aleatória fixada em 42 para reprodutibilidade, otimizador Adam com taxa de aprendizado $\eta = 10^{-4}$, tamanho de lote de 4 imagens, e função de perda Cross-Entropy Loss (ignorando o índice 255, reservado a pixels não rotulados), calculada sobre os 12 canais de classe. O treinamento foi executado em GPU no ambiente Google Colab.

3.4. Detalhes de Implementação

O modelo foi instanciado a partir da implementação `deeplabv3\_resnet50` da biblioteca TorchVision (Paszke et al., 2019), carregado com os pesos pré-treinados padrão (COCO/ImageNet) e adaptado para o número de classes do CamVid: as camadas convolucionais finais dos módulos `classifier` e `aux\_classifier` foram substituídas por convoluções 1×1 com 12 canais de saída, preservando o restante da rede — incluindo o módulo ASPP e o backbone ResNet-50 — com os pesos pré-treinados como ponto de partida (transfer learning). Cada experimento instanciou seu próprio modelo e otimizador de forma independente, garantindo que não houvesse contaminação de pesos entre as configurações de resolução 128×256 e 256×512.

3.5. Métricas de Avaliação

O monitoramento quantitativo do desempenho das curvas assentou-se sobre duas métricas centrais: a Cross-Entropy Loss, que mede a discrepância estatística entre a distribuição de probabilidades predita pela camada Softmax do modelo e o rótulo real em nível de pixel; e o Mean Intersection over Union (mIoU), métrica padrão da literatura para segmentação semântica, que quantifica a interseção geométrica sobre a união das previsões do modelo em face do gabarito real, calculada para cada classe e agregada pela média entre as classes presentes em cada lote. Ambas as métricas foram computadas separadamente para os subconjuntos de treino e de validação a cada época, permitindo o acompanhamento simultâneo da capacidade de ajuste aos dados de treino e da capacidade de generalização do modelo.

4. Resultados e Análise

4.1. Avaliação Quantitativa Final

A Tabela 1 resume os resultados finais (última época de validação) obtidos para cada configuração experimental.

Experimento	Perda de Validação	mIoU de
Exp. 1 (128×256)	0,7071	31,
Exp. 2 (256×512)	0,5448	36,

Tabela 1. Desempenho quantitativo final comparativo obtido entre as resoluções de entrada (última época).

O Experimento 2 (resolução 256×512) superou o Experimento 1 tanto na perda de validação final (0,5448 contra 0,7071) quanto no mIoU de validação (36,43% contra 31,28%), uma diferença de aproximadamente 5,15 pontos percentuais. Isso é consistente com a hipótese de que a retenção de uma matriz espacial mais densa preserva componentes de alta frequência e bordas de transição entre classes semânticas urbanas.

4.2. Evolução do Treinamento

As Tabelas 2 e 3 detalham a evolução época a época de cada experimento, e a Figura 1 apresenta as curvas correspondentes de perda e mIoU de validação.

Época	Loss Treino	Loss Val.
1	1,3508	1,0763
2	0,9129	0,9187
3	0,7932	0,6835
4	0,6897	0,6082
5	0,6275	0,7071

Tabela 2. Histórico de treinamento por época — Experimento 1 (128×256).

Época	Loss Treino	Loss Val.
1	1,2848	0,8645
2	0,8932	0,6996
3	0,7780	0,6527
4	0,6687	0,5393
5	0,6111	0,5448

Tabela 3. Histórico de treinamento por época — Experimento 2 (256×512).




Figura 1. Curvas de perda (Cross-Entropy) e evolução do mIoU de validação para os Experimentos 1 e 2 ao longo das 5 épocas.

4.3. Discussão Comparativa

As curvas de aprendizado revelam que o Experimento 2 partiu de um patamar de mIoU superior já na primeira época (35,56% contra 23,39%) e manteve-se consistentemente acima do Experimento 1 ao longo de todo o treinamento, confirmando que a maior densidade espacial de entrada favorece a convergência desde os estágios iniciais. Observa-se, contudo, que nenhum dos dois experimentos apresentou uma curva estritamente monotônica: o Experimento 1 atingiu seu melhor mIoU de validação já na época 3 (34,83%), recuando nas épocas seguintes até 31,28%; o Experimento 2 oscilou entre um pico de 37,60% (época 2) e 37,56% (época 4), fechando em 36,43% na época 5.

Esse comportamento não monotônico é esperado dado o tamanho reduzido do conjunto de

treinamento do CamVid (367 imagens) frente à complexidade da tarefa de segmentação em 12 classes, o que torna o processo de validação mais sensível a variações estatísticas de um lote para outro, além de indicar sinais iniciais de sobreajuste (overfitting) a partir da época 3 no Experimento 1. Ainda assim, o padrão geral de superioridade do Experimento 2 permanece consistente com a hipótese inicial: maior resolução de entrada favorece a captura de bordas finas, como as que separam a via da calçada.

Do ponto de vista de custo computacional, o Experimento 2 processa quatro vezes mais pixels por imagem do que o Experimento 1, conforme sintetizado na Tabela 4, o que se traduz em maior tempo de treinamento por época e maior consumo de memória de GPU. Esse é um compromisso relevante em aplicações de direção autônoma embarcadas, nas quais a inferência precisa ocorrer em tempo real: o ganho de 5,15 pontos percentuais de mIoU obtido pelo Experimento 2 neste estudo deve ser ponderado frente ao custo computacional adicional em cenários de implantação com restrição de hardware, como computadores de bordo veiculares.

Resolução	Pixels/imagem	Fator de aumento
128×256	32.768	1×
256×512	131.072	4×

Tabela 4. Comparativo do custo espacial (número de pixels processados por imagem) entre as duas resoluções avaliadas.

4.4. Análise Visual de Erros

A Figura 2 e a Figura 3 apresentam exemplos qualitativos de segmentação do conjunto de teste para os Experimentos 1 e 2, respectivamente, comparando a imagem original, a máscara real (ground truth) e a predição do modelo.



Figura 2. Exemplos de segmentação qualitativa do Experimento 1 (128×256): imagem original, máscara real e predição do DeepLabV3.




Figura 3. Exemplos de segmentação qualitativa do Experimento 2 (256×512): imagem original, máscara real e predição do DeepLabV3.

Visualmente, observa-se que ambos os modelos capturam a estrutura geral da cena (via, céu e vegetação), porém as predições do Experimento 1 apresentam regiões mais fragmentadas e ruído de contorno nas áreas limítrofes entre classes, especialmente entre via e calçada — consistente com o mIoU mais baixo observado quantitativamente. O Experimento 2 apresenta regiões mais homogêneas e contínuas, com menor presença de pixels espúrios isolados.

4.5. Limitações do Estudo

Este estudo apresenta limitações relevantes que devem ser consideradas na interpretação dos resultados. Primeiramente, por indisponibilidade de acesso automatizado ao Cityscapes, o experimento foi conduzido no CamVid, um dataset de cenas urbanas menor (367 imagens de treino) e com um conjunto de classes distinto (12 classes) do Cityscapes original (19 classes + background), o que limita a comparação direta com trabalhos que utilizam o Cityscapes propriamente dito. Em segundo lugar, o treinamento foi conduzido por apenas 5 épocas, número reduzido frente ao comumente empregado em benchmarks de segmentação semântica, e a curva não monotônica do Experimento 1 sugere que um número maior de épocas, aliado a técnicas de regularização e a um agendador de taxa de aprendizado, poderia estabilizar e melhorar ainda mais os resultados de ambos os experimentos.

Adicionalmente, o tamanho de lote reduzido (batch size = 4), adotado para viabilizar o treinamento dentro dos limites de memória de GPU disponíveis gratuitamente no Google Colab, também pode ter contribuído para a instabilidade observada nas curvas de validação, uma vez que lotes pequenos produzem estimativas de gradiente mais ruidosas a cada passo de otimização. Por fim, cada experimento foi executado uma única vez, sem repetições com sementes aleatórias distintas; assim, não é possível quantificar a variância estatística dos resultados obtidos, o que é recomendável para trabalhos futuros que busquem maior robustez metodológica.

5. Conclusões e Considerações Finais

Esta investigação experimental, realizada no IFPI Campus Corrente, cumpriu o objetivo de avaliar a influência das dimensões espaciais de entrada na segmentação de cenas urbanas por meio do DeepLabV3 (ResNet-50), com treinamento real em GPU sobre o dataset público CamVid. Ficou evidenciado que o modelo operando na resolução 256×512 entrega melhores respostas quantitativas (mIoU de 36,43% contra 31,28%) e qualitativas, com segmentações mais homogêneas e menor ruído de contorno, em comparação com a resolução mais baixa (128×256), ainda que ambos os experimentos tenham exibido sinais de instabilidade na validação, atribuíveis ao tamanho reduzido do conjunto de treinamento e ao número limitado de épocas.

De forma geral, os achados reforçam que a resolução de entrada não é um mero hiperparâmetro secundário, mas uma decisão de projeto com impacto direto na qualidade da delimitação de bordas em tarefas de segmentação urbana — um fator crítico para a segurança de sistemas de percepção em veículos autônomos. Como trabalhos futuros, sugere-se estender o treinamento para um número maior de épocas, introduzir técnicas adicionais de aumento de dados, testar backbones alternativos mais profundos (como ResNet-101), avaliar o custo de inferência em tempo real em hardware embarcado e, quando possível, validar os achados diretamente no Cityscapes mediante acesso autenticado ao dataset original.

Agradecimentos

O presente trabalho foi realizado com apoio institucional do Instituto Federal de Educação, Ciência e Tecnologia do Piauí (IFPI) — Campus Corrente, sob a orientação da disciplina de Inteligência Artificial conduzida pelo Prof. Msc. Igor Bezerra Reis.

Referências

- Chen, L.-C.; Papandreou, G.; Schroff, F.; Adam, H. (2017). Rethinking Atrous Convolution for Semantic Image Segmentation. arXiv preprint arXiv:1706.05587.
- Cordts, M. et al. (2016). The Cityscapes Dataset for Semantic Urban Scene Understanding. In: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 3213-3223.
- He, K. et al. (2016). Deep Residual Learning for Image Recognition. In: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 770-778.
- Long, J.; Shelhamer, E.; Darrell, T. (2015). Fully Convolutional Networks for Semantic Segmentation. In: Proceedings of the IEEE

Conference on Computer Vision and Pattern Recognition (CVPR).

Paszke, A. et al. (2019). PyTorch: An Imperative Style, High-Performance Deep Learning Library. In: Advances in Neural Information Processing Systems (NeurIPS), pp. 8024-8035.

Ronneberger, O.; Fischer, P.; Brox, T. (2015). U-Net: Convolutional Networks for Biomedical Image Segmentation. In: Medical Image Computing and Computer-Assisted Intervention (MICCAI), Springer, pp. 234-241.